

RAPPORT D'ANALYSE STATISTIQUE ET DE SCORING

Projet : Lancement de la Carte de Fidélité Intersport

Auteur : AFFOUDJI Paterne

Date : 5 Février 2026

Objet : Segmentation de la clientèle et élaboration d'un modèle prédictif d'adhésion.

1. Introduction et Audit de la Base de Données

L'objectif de cette étude est d'identifier les déterminants de l'adhésion à la future carte de fidélité (variable cible **Q10**) et de fournir un outil de décision pour le ciblage marketing. L'analyse repose sur un échantillon représentatif de **225 clients**.

1.1 Fiabilité des données

Avant toute modélisation, un audit qualité a été réalisé :

- **Exhaustivité** : Aucune valeur manquante n'a été détectée (225 questionnaires complets).
- **Cohérence** : Les filtres logiques (ex: lien entre Q1 *Achat* et Q2 *Raison de non-achat*) sont strictement respectés. La base est saine.

1.2 Description de la cible

La variable à prédire (Q10 : "Êtes-vous intéressé par la carte ?") présente une répartition équilibrée, idéale pour l'apprentissage statistique :

- **Oui (Intéressés)** : 49 %
- **Non (Pas intéressés)** : 51 %

2. Méthodologie de Sélection des Variables (Le "Filtrage")

Pour construire le modèle, nous n'avons pas conservé toutes les questions. Nous avons procédé en deux étapes pour ne garder que les indicateurs pertinents.

Étape 1 : Analyse Bivariée (La force brute)

Nous avons d'abord testé chaque variable individuellement face à Q10 en utilisant le **V de Cramer**. Cela nous a permis d'établir un "Top 15" des prédicteurs potentiels.

- **Les "Stars"** : Le Montant par visite (Q7, $V=0.54$), la Pratique en Club (Q23, $V=0.46$) et l'Âge (Q18, $V=0.41$) sont ressortis comme les liens les plus puissants.
- **L'exclusion technique** : Les variables Q11 et Q13, bien que très liées ($V=1.0$), ont été exclues car elles sont conditionnées par la réponse "Non" à la carte. Les inclure aurait faussé le modèle.

Étape 2 : Analyse et Sélection Multivariée

Avant de lancer le modèle prédictif final, nous avons analysé les interactions entre les variables pour ne garder que les plus pertinentes et éviter les redondances.

2.1. Confirmation Visuelle par l'ACM

Nous avons réalisé une **Analyse des Correspondances Multiples (ACM)** pour visualiser la structure des données.

- **Observation** : La carte factorielle révèle une forte proximité géométrique entre la possession de la carte (Q10_Oui), l'appartenance à un club (Q23_Oui) et le genre féminin.
- **Interprétation** : L'ACM valide l'existence d'un "écosystème" cohérent : ces variables ne sont pas indépendantes, elles définissent ensemble le profil d'engagement. Cela nous indique que ces variables seront des prédicteurs forts.

2.2. Optimisation du Modèle (Gestion de la Multicolinéarité)

C'est ici que nous avons affiné la sélection mathématique. Certaines variables, bien que performantes seules (en bivarié), deviennent inutiles lorsqu'elles sont combinées aux autres.

Point Méthodologique Crucial (Le cas de la Fréquence Q4) :

- Lors de l'analyse bivariée, la Fréquence de visite (Q4) montrait une p-value très significative (< 0.05).
- Pourtant, nous l'avons **exclue** du modèle final.
- **Pourquoi ?** Dans la régression logistique (multivariée), la p-value de Q4 est remontée au-dessus de 0.05 (non significatif).

- **Explication** : L'information contenue dans la "Fréquence" était **redondante**. L'ACM et les tests montrent qu'un client fréquent est souvent corrélé à un certain Âge ou Budget. Le modèle préfère utiliser l'Âge (Q18) et le Budget (Q7) qui sont des indicateurs plus stables. Supprimer Q4 a permis d'alléger le modèle sans perdre en précision.

3. Typologie des Clients (Segmentation K-Means)

Afin de comprendre "qui" sont nos clients, nous avons utilisé l'algorithme de clustering **K-Means** sur 9 variables clés. Cette approche a permis d'identifier trois profils types bien distincts.

Cluster 1 : "Le Cœur de Cible" (102 clients)

- **Profil** : Ce groupe est le plus jeune et le plus féminin. Ce sont des sportifs engagés (inscrits en club) avec un budget élevé.
- **Relation** : Très satisfaits et déjà clients réguliers.
- **Intérêt Carte** : **Maximal (~100 % de "Oui")**. C'est le segment prioritaire.

Cluster 2 : "Les Fidèles Résistants" (74 clients)

- **Profil** : Clients plus âgés (40+ ans).
- **Relation** : Ils sont fidèles et viennent par habitude, mais leur panier moyen est plus modéré.
- **Intérêt Carte** : **Nul (97 % de "Non")**. Ils aiment le magasin mais rejettent l'outil marketing. Inutile de les solliciter.

Cluster 3 : "Les Visiteurs Volatils" (49 clients)

- **Profil** : Nouveaux visiteurs, souvent attirés par la publicité ou la curiosité.
- **Relation** : Pas encore d'historique d'achat fort.
- **Intérêt Carte** : Très faible. Ils ne sont pas assez "mûrs" pour être fidélisés immédiatement.

4. Le Modèle de Scoring Final (Régression Logistique)

Pour passer de la description à la **prédiction**, nous avons choisi la Régression Logistique. Ce modèle permet d'attribuer un "poids" mathématique exact à chaque caractéristique client.

4.1 Performance du Modèle

Le modèle final, purifié des variables inutiles (comme Q4 ou Q16), conserve 7 variables stratégiques.

- **Pseudo R-Squared : 0.5134.** Ce score est excellent pour une étude comportementale (supérieur au standard de 0.30), indiquant que le modèle explique plus de 50 % de la décision d'adhésion.
- **Précision (Accuracy) : 85,33 %.** Concrètement, sur 100 clients, le modèle devine correctement la décision d'adhésion pour 85 d'entre eux.

4.2 Les 7 Leviers du Score (Coefficients)

Voici les facteurs qui augmentent ou diminuent le score d'appétence, classés par impact :

1. **La Pratique en Club (Q23) [+1.26]** : Le levier le plus puissant. Un licencié sportif est quasi-certain de dire oui.
2. **L'Âge (Q18) [-1.10]** : Le frein le plus fort. Plus le client est âgé, plus la probabilité d'adhésion s'effondre.
3. **Le Sexe (Q17) [+1.01]** : À profil égal, une femme a une probabilité d'adhésion nettement supérieure à un homme.
4. **Le Budget Visite (Q7) [+0.97]** : Un panier moyen élevé est un signe direct d'intérêt pour la fidélité.
5. **Le Budget Annuel (Q21) [+0.63]** : Le potentiel d'achat global sur l'année joue un rôle complémentaire positif.
6. **La Motivation (Q3) [-0.45]** : Venir par "Habitude" (codes bas) est plus positif que venir par "Hasard" (codes élevés).
7. **L'Habitude d'Achat (Q6) [-0.56]** : Les acheteurs systématiques (Code 1) ont un meilleur score que les flâneurs.

5. Conclusion et Recommandations Stratégiques

Cette étude a permis de transformer des données brutes en un plan d'action opérationnel.

1. Le Ciblage "Chirurgical" : L'effort de lancement doit se concentrer exclusivement sur le Cluster 1.

- *Persona Idéal* : Femme de moins de 30 ans, pratiquant en club, dépensant plus de 60€ par visite.

2. L'Économie de Moyens : Il est recommandé de ne **pas** proposer la carte proactivement aux clients du **Cluster 2** (Fidèles Résistants). Bien que loyaux à l'enseigne, leur score prédictif montre qu'ils percevront la carte comme une nuisance, risquant d'altérer leur satisfaction.

3. L'Outil Technique : Un script Python a été développé pour automatiser ce calcul. Il permet d'attribuer une note de 0 à 1 à tout nouveau prospect.

- *Score* > 0.60 : Proposer la carte immédiatement.
- *Score* < 0.40 : Ne pas proposer.