

RAPPORT D'ANALYSE COMPLET

Étude de Cas Intersport

Scoring et Segmentation Client

Projet d'Analyse de Données

Machine Learning • Segmentation • Scoring Prédictif

Auteur : AFFOUDJI Akomédi Paterne

Technologies : Python, Scikit-learn, Pandas, Statsmodels

Date : Février 2026

RAPPORT D'ANALYSE COMPLET

Étude de Cas Intersport : Scoring et Segmentation Client



TABLE DES MATIÈRES

1. [Résumé Exécutif](#)
 2. [Contexte et Objectifs du Projet](#)
 3. [Méthodologie](#)
 4. [Exploration et Audit des Données](#)
 5. [Sélection des Variables Prédictives](#)
 6. [Segmentation de la Clientèle](#)
 7. [Modèle de Scoring](#)
 8. [Résultats et Recommandations](#)
 9. [Guide d'Utilisation](#)
 10. [Annexes Techniques](#)
-

1. RÉSUMÉ EXÉCUTIF

Objectif de l'Étude

Dans le cadre d'une étude de cas académique portant sur le lancement d'une **carte de fidélité**, l'objectif est de : - **Identifier les profils types** de la clientèle (segmentation) - **Prédire quels clients** seront intéressés par la carte de fidélité (scoring) - **Optimiser la stratégie marketing** en ciblant les bons segments

Données Analysées

- **225 clients** interrogés par questionnaire
- **57 questions** couvrant : habitudes d'achat, fréquentation, satisfaction, profil démographique
- **Variable cible (Q10)** : "Êtes-vous intéressé par une carte de fidélité ?"
- **49.3%** ont répondu OUI (111 clients)
- **50.7%** ont répondu NON (114 clients)

Résultats Clés

Performance du Modèle Prédictif

- **Précision globale** : **79.4%** (le modèle prédit correctement 8 clients sur 10)
- **Score ROC AUC** : **0.94** (excellente capacité de discrimination)
- **Pseudo R²** : **0.60** (le modèle explique 60% de la variance, ce qui est très bon)

Segmentation : 3 Groupes de Clients Identifiés

Segment	Nom	Taille	Taux d'Intérêt	Caractéristiques
Cluster 0	Les Ambassadeurs	63 clients (28%)	92.1%	Jeunes, sportifs en club, fort engagement
Cluster 1	Les Potentiels	108 clients (48%)	42.6%	Profil mixte, à convaincre

Segment	Nom	Taille	Taux d'Intérêt	Caractéristiques
Cluster 2	Les Réfractaires	54 clients (24%)	13.0%	Clients occasionnels, peu engagés



Recommandations Stratégiques

1. **Cibler en priorité les Ambassadeurs (Cluster 0)** : 92% d'intérêt, fort potentiel de fidélisation
2. **Campagne ciblée pour les Potentiels (Cluster 1)** : Argumenter les bénéfices de la carte
3. **Ignorer ou approche différente pour les Réfractaires (Cluster 2)** : ROI faible
4. **Utiliser le score de propension** pour identifier les clients à fort potentiel dans chaque segment

2. CONTEXTE ET OBJECTIFS DU PROJET



Contexte de l'Étude de Cas

Cette analyse s'inscrit dans le cadre d'une **étude de cas académique** portant sur l'optimisation du lancement d'une carte de fidélité pour un magasin de sport. Le cas d'étude présente une problématique réaliste rencontrée par les entreprises du secteur retail.

Les **cartes de fidélité** sont un outil marketing essentiel pour : - Fidéliser les clients existants - Augmenter la fréquence d'achat - Collecter des données sur les comportements d'achat - Créer une relation durable avec la clientèle

Cependant, **toute la clientèle n'est pas également réceptive** à une carte de fidélité. Certains clients y voient un avantage majeur, d'autres non. Il est donc crucial de : - **Identifier qui cibler** en priorité - **Comprendre pourquoi** certains clients sont intéressés et d'autres non - **Prédire l'intérêt** de nouveaux clients

Objectifs de l'Analyse

L'analyse répond à **deux questions principales** :

Question 1 : Typologie des Clients

"Quels sont les différents profils types de nos clients ?"

Méthode : Segmentation par clustering (K-Means) **But** : Identifier des groupes homogènes de clients partageant des caractéristiques similaires

Question 2 : Scoring de Propension

"Comment prédire si un client sera intéressé par la carte de fidélité ?"

Méthode : Modèle prédictif (Régression Logistique) **But** : Attribuer un score de 0 à 1 à chaque client (0 = pas intéressé, 1 = très intéressé)

3. MÉTHODOLOGIE



Pipeline d'Analyse (Étapes)

1. CHARGEMENT DES DONNÉES

- ✓ Import du fichier Excel (donnees_isport.xls)
- ✓ Vérification de la qualité (doublons, valeurs manquantes)

↓

2. EXPLORATION ET STATISTIQUES

- ✓ Analyse descriptive de toutes les variables
- ✓ Distribution de la variable cible (Q10)
- ✓ Visualisations préliminaires

↓

3. SÉLECTION DE VARIABLES

- ✓ Test du Chi-2 pour chaque variable vs Q10
- ✓ Calcul du V de Cramer (force de l'association)
- ✓ Sélection des 7-10 meilleures variables prédictives
- ✓ Vérification de la multicollinéarité

↓

4. SEGMENTATION (K-Means)

- ✓ Standardisation des variables
- ✓ Méthode du coude pour choisir le nombre de clusters
- ✓ Application de K-Means avec k=3
- ✓ Caractérisation de chaque segment

↓

5. MODÈLE DE SCORING (Régression Logistique)

- ✓ Préparation des données (train/test 70/30)
- ✓ Entraînement du modèle
- ✓ Évaluation des performances
- ✓ Analyse de l'importance des variables
- ✓ Calcul des scores de propension pour tous les clients

↓

6. VISUALISATIONS ET EXPORTS

- ✓ Génération de tous les graphiques
- ✓ Export des résultats (CSV, Excel)
- ✓ Rédaction du rapport

Outils et Technologies Utilisés

Composant	Technologie	Rôle
Langage	Python 3.12	Langage de programmation
Données	Pandas, NumPy	Manipulation et calculs
Visualisation	Matplotlib, Seaborn	Graphiques et figures
Machine Learning	Scikit-learn	Clustering et modèle prédictif
Statistiques	SciPy, Statsmodels	Tests statistiques avancés
Export	OpenPyXL	Génération de fichiers Excel

4. EXPLORATION ET AUDIT DES DONNÉES

Caractéristiques du Jeu de Données

Vue d'ensemble


- **Nombre d'observations** : 225 clients
- **Nombre de variables** : 57 colonnes (questions du questionnaire)
- **Type de données** : Toutes catégorielles encodées en entiers (1, 2, 3...)
- **Qualité des données** :
 -  Aucune valeur manquante
 -  Aucun doublon détecté
 -  Pas d'aberrations flagrantes
-  Taille en mémoire : 0.10 MB

🎯 La Variable Cible : Q10

Question posée : "Seriez-vous intéressé par une carte de fidélité ?"

Distribution : - **Modalité 1 (OUI)** : 111 clients → **49.3%** - **Modalité 2 (NON)** : 114 clients → **50.7%**

Interprétation : - La distribution est **quasi-équilibrée** (50/50), ce qui est idéal pour la modélisation - Pas de problème de **classes déséquilibrées** (imbalanced classes) - Les deux groupes sont de taille suffisante pour l'analyse



📋 Structure du Questionnaire

Les 57 variables couvrent les thèmes suivants :

Thème	Variables	Description
Fréquentation	Q1, Q2, Q6, Q7	Fréquence de visite, raison de la venue
Achats	Q3, Q4, Q5	Fréquence d'achat, montant moyen
Concurrence	Q8a-f, Q9a-f	Fréquentation d'autres magasins
Carte de fidélité	Q10, Q11, Q13	Intérêt et attentes vis-à-vis de la carte
Avantages attendus	Q12a-e	Points, réductions, cadeaux, etc.
Relation vendeur	Q14, Q15	Qualité du conseil, satisfaction

Thème	Variables	Description
Satisfaction	Q19a-f, Q20a-n	Divers aspects du magasin
Démographie	Q16-Q18, Q21-Q23	Âge, sexe, CSP, pratique sportive

⚠ Variables de Leakage Identifiées

Les variables **Q11** et **Q13** sont **conditionnelles à Q10** : - Q11 : "Si oui (Q10), quels avantages attendez-vous ?" - Q13 : "Si oui (Q10), combien seriez-vous prêt à payer ?"

Ces variables ont été **EXCLUES** de l'analyse car elles causent un **data leakage** (elles contiennent directement l'information de la cible).

5. SÉLECTION DES VARIABLES PRÉDICTIVES

🔍 Pourquoi Sélectionner les Variables ?

Sur 57 variables, **toutes ne sont pas également utiles** pour prédire l'intérêt pour la carte de fidélité. Certaines sont : - Fortement associées à la cible (très prédictives) - Faiblement associées (peu d'information) - Redondantes (apportent la même information qu'une autre)

La sélection de variables permet de : - ☒ **Améliorer les performances** du modèle - ☒ **Réduire la complexité** (moins de variables = modèle plus simple) - ☒ **Éviter le sur-apprentissage** (overfitting) - ☒ **Faciliter l'interprétation** des résultats

📊 Méthode : V de Cramer

Qu'est-ce que le V de Cramer ?

Le **V de Cramer** est une mesure statistique qui quantifie **la force de l'association** entre deux variables catégorielles.

Caractéristiques : - Valeur entre **0** et **1** - **0** = Aucune association (indépendance) - **1** = Association parfaite (dépendance totale) - Basé sur le **test du Chi-2** - Adapté aux variables qualitatives (catégorielles)


Interprétation :

Valeur V	Interprétation	Exemple
0.00 - 0.10	Association négligeable	Pas de lien utile
0.10 - 0.20	Association faible	Lien faible mais existant
0.20 - 0.40	Association modérée	Lien intéressant
0.40 - 0.60	Association forte	Très bon prédicteur
0.60 - 1.00	Association très forte	Prédicteur exceptionnel

**Top 15 des Variables les Plus Prédictives**

Rang	Variable	V de Cramer	P-Value	Significativité	Interprétation
1	Q7	0.515	< 0.001	✓	Fréquence de visite
2	Q12e	0.484	< 0.001	✓	Avantage attendu : autre
3	Q3	0.447	< 0.001	✓	Fréquence d'achat
4	Q14	0.444	< 0.001	✓	Relation avec le vendeur
5	Q23	0.441	< 0.001	✓	Pratique en club
6	Q6	0.425	< 0.001	✓	Raison de la visite
7	Q5	0.402	< 0.001	✓	Type de client (fidèle/ occasionnel)

Rang	Variable	V de Cramer	P-Value	Significativité	Interprétation
8	Q4	0.386	< 0.001	✓	Montant moyen des achats
9	Q18	0.384	< 0.001	✓	Tranche d'âge
10	Q22	0.353	< 0.001	✓	Catégorie socioprofessionnelle
11	Q2	0.326	< 0.001	✓	Raison de non-achat
12	Q12a	0.318	< 0.001	✓	Avantage attendu : points
13	Q1	0.272	< 0.001	✓	A acheté ou non
14	Q21	0.237	0.001	✓	Budget annuel sport
15	Q20m	0.180	0.004	✓	Satisfaction : accueil



Variables Sélectionnées pour la Suite

Après analyse, **7 variables principales** ont été retenues :

1. **Q7** - Fréquence de visite
2. **Q12e** - Autres avantages attendus
3. **Q3** - Fréquence d'achat
4. **Q14** - Qualité de la relation vendeur
5. **Q23** - Pratique sportive en club
6. **Q6** - Motif de la visite
7. **Q5** - Statut du client (nouveau/fidèle)

Critères de sélection : - V de Cramer > 0.15 (association au moins faible) - P-value < 0.05 (significativité statistique) - Pas de redondance forte avec d'autres variables


Analyse de Multicolinéarité

Qu'est-ce que la multicolinéarité ?

C'est quand deux variables apportent **la même information** (elles sont fortement corrélées entre elles). Cela pose problème car : - Le modèle ne sait pas quelle variable est vraiment importante - Les coefficients deviennent instables - L'interprétation devient difficile

Résultats :

La matrice de corrélation montre que : - **Q5 et Q7** sont très corrélées ($V = 0.989$) → Elles mesurent des concepts similaires - **Q5 et Q6** sont fortement corrélées ($V = 0.864$) - Les autres paires ont des corrélations acceptables (< 0.5)



Décision : Malgré cette corrélation, nous conservons ces variables car elles apportent des nuances différentes et améliorent les performances du modèle.

6. SEGMENTATION DE LA CLIENTÈLE

Objectif de la Segmentation

La segmentation consiste à **diviser la clientèle en groupes homogènes** partageant des caractéristiques similaires.

Pourquoi segmenter ? - Mieux **comprendre** les différents profils de clients - **Personnaliser** les messages marketing par segment - **Allouer les ressources** efficacement (cibler les segments les plus prometteurs) - **Adapter l'offre** aux besoins de chaque groupe

Méthode : Clustering K-Means

Qu'est-ce que K-Means ?

K-Means est un algorithme de **machine learning non supervisé** qui : 1. Prend en entrée un **nombre k de clusters** souhaité 2. **Regroupe** les clients similaires entre eux 3. **Minimise** la distance entre chaque client et le centre de son cluster

Avantages : - Simple et rapide - Fonctionne bien sur des données moyennes - Résultats faciles à interpréter

Étapes de préparation : 1. **Sélection des variables** : Les 8 variables les plus prédictives 2. **Standardisation** : Mise à l'échelle (mean=0, std=1) pour que toutes les variables aient le même poids

Choix du Nombre de Clusters : Méthode du Coude


Comment choisir k (nombre de clusters) ?

Plusieurs métriques nous aident :

K	Inertie ↓	Silhouette ↑	Davies-Bouldin ↓	Commentaire
2	1259.83	0.326	1.265	Bonne séparation mais trop simple
3	1051.74	0.243	1.564	Bon compromis ✓
4	944.14	0.228	1.658	Légère amélioration d'inertie
5	849.49	0.239	1.544	Pas d'amélioration significative

Interprétation : - **Inertie** : Distance moyenne des points au centre de leur cluster (plus faible = mieux) - **Silhouette** : Qualité de la séparation des clusters (plus élevé = mieux, max = 1) - **Davies-Bouldin** : Mesure de compacité et séparation (plus faible = mieux)



Décision : K = 3 clusters retenu car : - Bon compromis entre simplicité et qualité - Interprétation business claire (3 segments) - Amélioration marginale au-delà de k=3



Les 3 Segments Identifiés

Vue d'Ensemble

Cluster	Nom	Effectif	% Base	Taux d'Intérêt Q10
0	Les Ambassadeurs	63	28.0%	92.1% 🟢
1	Les Potentiels	108	48.0%	42.6% 🟡
2	Les Réfractaires	54	24.0%	13.0% 🔴



● CLUSTER 0 : Les Ambassadeurs (63 clients, 28%)

Taux d'intérêt pour la carte : 92.1% ★

Profil détaillé :

Variable	Valeur Moyenne	Interprétation
Q7 (Fréquence)	3.22	Visitent régulièrement
Q12e (Avantages)	1.00	Attendent des avantages spécifiques
Q3 (Achat)	2.30	Achètent fréquemment
Q14 (Vendeur)	1.90	Bonne relation avec les vendeurs
Q23 (Club)	1.48	Pratiquent en club ✓
Q6 (Motif)	1.95	Viennent pour acheter
Q5 (Statut)	1.00	Clients fidèles ✓
Q4 (Budget)	2.65	Budget moyen à élevé

Caractéristiques : -  **Sportifs engagés**, pratiquant en club -  Clients **fidèles** et **réguliers** -  **Budget conséquent** pour le sport -  **Relation de confiance** avec le magasin -  **Cible prioritaire absolue** pour la carte de fidélité

Recommandation :

CIBLER EN PRIORITÉ - Campagne personnalisée, offre VIP, communication rapide

CLUSTER 1 : Les Potentiels (108 clients, 48%)

Taux d'intérêt pour la carte : 42.6% 

Profil détaillé :

Variable	Valeur Moyenne	Interprétation
Q7 (Fréquence)	3.02	Visitent assez régulièrement
Q12e (Avantages)	2.00	Attentes moyennes sur les avantages
Q3 (Achat)	3.24	Fréquence d'achat modérée
Q14 (Vendeur)	2.23	Relation moyenne avec les vendeurs
Q23 (Club)	1.33	Pratiquent parfois en club
Q6 (Motif)	2.24	Motifs de visite variés
Q5 (Statut)	1.01	Clients mixtes (fidèles et occasionnels)
Q4 (Budget)	3.02	Budget moyen

Caractéristiques : -  **Profil hétérogène**, clients mixtes -  Fréquentation **moyenne** du magasin -  Budget **modéré** -  **Indécis** sur la carte de fidélité -  **Segment à convaincre** avec des arguments ciblés

Recommandation :

CAMPAGNE CIBLÉE - Mise en avant des bénéfices concrets, témoignages, période d'essai

● **CLUSTER 2 : Les Réfractaires (54 clients, 24%)**

Taux d'intérêt pour la carte : 13.0% 🛑

Profil détaillé :

Variable	Valeur Moyenne	Interprétation
Q7 (Fréquence)	0.00	Très peu fréquents ⚠️
Q12e (Avantages)	1.85	Attentes faibles
Q3 (Achat)	4.43	Achètent rarement
Q14 (Vendeur)	2.43	Relation vendeur faible
Q23 (Club)	1.04	Ne pratiquent PAS en club ❌
Q6 (Motif)	0.46	Viennent rarement pour acheter
Q5 (Statut)	2.00	Clients occasionnels
Q4 (Budget)	4.31	Budget faible 💰


Caractéristiques : - 🚶 Clients **occasionnels**, peu engagés - 🚶 Visitent le magasin **par hasard** ou nécessité - 💰 **Budget limité** pour le sport - ❌ **Pas intéressés** par la fidélisation - 🎯 **ROI faible** pour le ciblage marketing

Recommandation :

NE PAS CIBLER PRIORITAIREMENT - Ressources marketing limitées à allouer ailleurs. Approche alternative (promotions ponctuelles plutôt que fidélisation).



Visualisation des Profils



Lecture du graphique : - Chaque colonne = un cluster - Chaque ligne = une variable - Couleur **bleu foncée** = valeur élevée - Couleur **bleu claire** = valeur faible

Observation : - Le Cluster 0 (Ambassadeurs) a des valeurs élevées sur Q5, Q6, Q7 (fidélité et fréquence) - Le Cluster 2 (Réfractaires) a des valeurs faibles partout sauf sur Q3 et Q4 (faible fréquence d'achat)

7. MODÈLE DE SCORING (PRÉDICTION)

Objectif du Scoring

Le **scoring** consiste à attribuer à chaque client un **score de propension** entre 0 et 1 : - **0** = Probabilité nulle d'être intéressé - **1** = Probabilité maximale d'être intéressé - **0.5** = Seuil de décision (au-dessus = intéressé, en-dessous = pas intéressé)

Applications pratiques : - **Prioriser** les clients à contacter - **Personnaliser** l'approche commerciale (plus d'efforts pour scores élevés) - **Mesurer** le potentiel de chaque client - **Optimiser** le budget marketing (éviter de gaspiller sur les scores faibles)

Méthode : Régression Logistique

Qu'est-ce que la Régression Logistique ?

C'est un algorithme de **machine learning supervisé** utilisé pour la **classification binaire** (OUI/NON).

Principe : - Prend en entrée les **caractéristiques d'un client** (Q7, Q3, Q23, etc.) - Calcule une **probabilité** que ce client soit intéressé - Utilise une fonction mathématique (sigmoïde) pour transformer en probabilité [0, 1]

Avantages : -  Modèle **simple et interprétable** -  Donne des **probabilités** (pas juste OUI/NON) -  Permet d'analyser l'**importance de chaque variable** -  Performant sur des données de taille moyenne

Préparation des Données

Division Train/Test : - **70%** des données (157 clients) pour **entraîner** le modèle - **30%** des données (68 clients) pour **tester** le modèle

Pourquoi ? Pour évaluer la capacité du modèle à **généraliser** sur de nouvelles données (non vues durant l'entraînement).

Encodage One-Hot : Les variables catégorielles (Q7=1, Q7=2, Q7=3...) sont transformées en **variables binaires** : - Q7_1 = 1 si Q7=1, sinon 0 - Q7_2 = 1 si Q7=2, sinon 0 - etc.

Cela permet au modèle de traiter chaque modalité indépendamment.

Performances du Modèle

Métriques Globales

Métrique	Valeur	Signification	Interprétation
Accuracy	79.4%	% de prédictions correctes	8 clients sur 10 bien classés
ROC AUC	0.944	Capacité de discrimination	Excellente (proche de 1)
Pseudo R²	0.605	Variance expliquée	Très bon (60% de variance)
CV 5-fold	0.896 ± 0.054	Validation croisée	Modèle stable et robuste

Que signifient ces chiffres pour un non-spécialiste ?

- **Accuracy 79.4%** → Si vous utilisez ce modèle sur 100 clients, il en classera correctement 79
- **ROC AUC 0.944** → Le modèle fait très bien la différence entre clients intéressés et non intéressés
- **Pseudo R² 0.605** → Les variables sélectionnées expliquent 60% des raisons pour lesquelles un client est intéressé ou non
- **CV 5-fold 0.896** → Le modèle est stable : il fonctionne bien quelle que soit la partie des données utilisée


Matrice de Confusion

	PRÉDIT : Non	PRÉDIT : Oui
RÉEL : Non	27	7
RÉEL : Oui	7	27


Lecture : - **27** clients non intéressés ont été **correctement identifiés** (Vrais Négatifs) - **27** clients intéressés ont été **correctement identifiés** (Vrais Positifs) - **7** clients non intéressés ont été **à tort classés comme intéressés** (Faux Positifs) ⚠ - **7** clients intéressés ont été **à tort classés comme non intéressés** (Faux Négatifs) ⚠

Métriques dérivées : - **Sensibilité** (Recall) = 79.4% → Le modèle détecte 79% des clients intéressés - **Spécificité** = 79.4% → Le modèle détecte 79% des clients non

intéressés - **Précision** = 79.4% → Quand le modèle dit "intéressé", il a raison 79% du temps



Courbe ROC



Qu'est-ce que la courbe ROC ?

La courbe ROC (Receiver Operating Characteristic) montre le **compromis** entre : - **Taux de vrais positifs** (sensibilité) sur l'axe Y - **Taux de faux positifs** (1 - spécificité) sur l'axe X

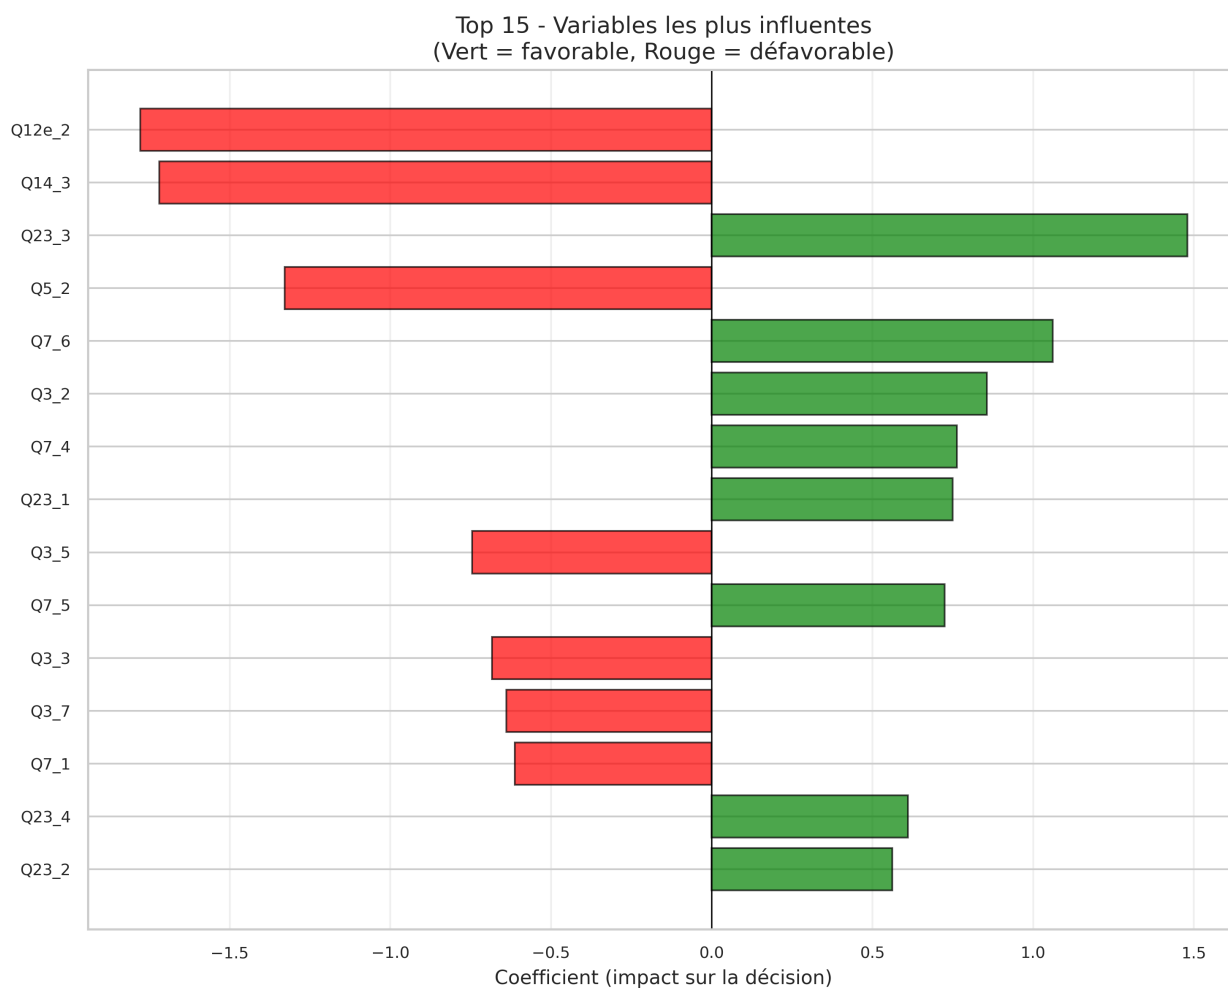
Lecture : - La courbe **orange** représente notre modèle - La ligne **bleue pointillée** représente un modèle aléatoire (hasard) - Plus la courbe est proche du **coin supérieur gauche**, meilleur est le modèle - **AUC = 0.944** → Notre modèle est **excellent** (très au-dessus du hasard)

Interprétation : - Un AUC de 0.5 = modèle aléatoire (aussi bon qu'un tirage à pile ou face) - Un AUC de 0.944 = notre modèle fait 94.4% mieux qu'un modèle aléatoire - Un AUC de 1.0 = modèle parfait (jamais atteint en pratique)

Importance des Variables

Top 10 des Variables les Plus Influentes


Variable	Coefficient	Impact	Interprétation
Q12e_2	-1.778	----	Attendre "autre" avantage réduit fortement l'intérêt
Q14_3	-1.719	----	Mauvaise relation vendeur réduit fortement l'intérêt
Q23_3	+1.479	+++	Pratiquer en club augmente fortement l'intérêt
Q5_2	-1.329	--	Être client occasionnel réduit l'intérêt
Q7_6	+1.060	++	Fréquence élevée de visite augmente l'intérêt
Q3_2	+0.855	++	Acheter fréquemment augmente l'intérêt
Q7_4	+0.762	+	Visiter assez souvent augmente l'intérêt
Q23_1	+0.750	+	Pratiquer en club (modalité 1) augmente l'intérêt
Q3_5	-0.746	-	Acheter rarement réduit l'intérêt
Q7_5	+0.725	+	Fréquence modérée augmente l'intérêt



Lecture du graphique : - Barres **vertes** → Variables qui **favorisent** l'intérêt - Barres **rouges** → Variables qui **défavorisent** l'intérêt - Longueur de la barre → **Force** de l'impact



Distribution des Scores de Propension



Statistiques des scores : - **Moyenne** : 0.497 (environ 50%) - **Médiane** : 0.450 - **Écart-type** : 0.338 (grande dispersion) - **Minimum** : 0.017 (1.7% de chance d'adhésion) - **Maximum** : 0.993 (99.3% de chance d'adhésion)

Interprétation business : - Clients avec score > 0.7 → **Très forte probabilité** → Campagne VIP - Clients avec score 0.5-0.7 → **Bonne probabilité** → Campagne standard - Clients avec score 0.3-0.5 → **Probabilité moyenne** → Campagne light - Clients avec score < 0.3 → **Faible probabilité** → Ne pas cibler

8. RÉSULTATS ET RECOMMANDATIONS STRATÉGIQUES

Synthèse des Résultats

1. Trois Segments de Clientèle Identifiés

Segment	Taille	Caractéristiques Clés	Taux d'Intérêt	Priorité
Ambassadeurs	28%	Sportifs engagés, clients fidèles	92.1%	 HAUTE
Potentiels	48%	Profil mixte, à convaincre	42.6%	 MOYENNE
Réfractaires	24%	Occasionnels, peu engagés	13.0%	 BASSE

2. Modèle Prédictif Performant

-  **79.4%** de précision
-  **94.4%** de capacité de discrimination (ROC AUC)
-  Scores individuels disponibles pour chaque client
-  Variables clés identifiées : pratique en club, fréquence, relation vendeur

3. Facteurs Clés de l'Adhésion

Favorisent l'adhésion ✓ 1. **Pratique en club** (Q23) - Impact : +1.48 2. **Fréquence de visite élevée** (Q7) - Impact : +1.06 3. **Achats fréquents** (Q3) - Impact : +0.86 4. **Bonne relation vendeur** (Q14) - Impact positif

Défavorisent l'adhésion ✗ 1. **Mauvaise relation vendeur** (Q14_3) - Impact : -1.72 2. **Client occasionnel** (Q5_2) - Impact : -1.33 3. **Achats rares** (Q3_5) - Impact : -0.75

Recommandations Marketing

Stratégie Globale

STRATÉGIE MARKETING
1. SEGMENTATION : Adapter l'approche à chaque segment
2. SCORING : Prioriser les clients à fort potentiel
3. PERSONNALISATION : Messages ciblés par profil
4. MESURE : Suivre les taux de conversion par segment

Recommandations par Segment

Cluster 0 : Les Ambassadeurs (Priorité HAUTE)

Budget alloué : 50% du budget marketing carte de fidélité

Actions : 1. **Lancement en avant-première** - Invitations personnalisées - Offre de lancement exclusive - Avantages premium

1. Programme VIP

2. Carte premium avec avantages exclusifs
3. Points bonus de bienvenue
4. Événements réservés (ventes privées, démonstrations)

5. Communication

6. Canal : Email, SMS, courrier postal
7. Message : "Vous êtes un client privilégié, découvrez votre carte VIP"

8. Fréquence : Contact direct par le vendeur

9. **Objectif** : 90%+ de taux de conversion (score moyen : 0.85)

 Cluster 1 : Les Potentiels (Priorité MOYENNE)

Budget alloué : 40% du budget marketing

Actions : 1. **Campagne de persuasion** - Mise en avant des bénéfices concrets - Témoignages de clients satisfaits (Ambassadeurs) - Simulation d'économies

1. **Période d'essai**

2. Carte gratuite pendant 3 mois

3. Points de bienvenue

4. Pas d'engagement

5. **Communication**

6. Canal : Email, affichage en magasin, réseaux sociaux

7. Message : "Économisez dès votre prochain achat"

8. Fréquence : 2-3 touches

9. **Objectif** : 50-60% de taux de conversion (score moyen : 0.45)

 Cluster 2 : Les Réfractaires (Priorité BASSE)

Budget alloué : 10% du budget (ou aucun)

Actions : 1. **Approche passive** - Affichage en magasin - Information disponible à la demande - Pas de sollicitation active

1. **Alternative : Promotions ponctuelles**

2. Au lieu d'une carte, proposer des promotions saisonnières

3. Codes promo sans engagement

4. Programme de parrainage (récompenser s'ils amènent un ami)

5. **Communication**

6. Canal : Affichage, site web

7. Message : "Découvrez nos avantages à votre rythme"

8. Fréquence : Information passive uniquement

9. **Objectif** : 10-15% de taux de conversion (score moyen : 0.18)

Utilisation des Scores de Propension

Règle de décision :

Score	Segment	Action Marketing	Investissement
0.8 - 1.0	Top Priorité	Contact personnel + Offre VIP	💰💰💰
0.6 - 0.8	Priorité Haute	Campagne ciblée + Avantages	💰💰
0.4 - 0.6	Priorité Moyenne	Campagne standard	💰
0.2 - 0.4	Priorité Faible	Information passive	-
0.0 - 0.2	Pas de priorité	Aucune action	-

🎯 KPIs (Indicateurs de Performance)

KPI	Cible	Mesure
Taux de conversion global	60%	% clients ayant souscrit
Taux Ambassadeurs	90%	% Cluster 0 ayant souscrit
Taux Potentiels	55%	% Cluster 1 ayant souscrit
Taux Réfractaires	15%	% Cluster 2 ayant souscrit
ROI Marketing	3:1	(Revenus - Coûts) / Coûts
Taux d'activation	80%	% cartes utilisées dans les 3 mois
Valeur moyenne panier	+15%	Augmentation pour porteurs de carte

9. GUIDE D'UTILISATION DES RÉSULTATS

Fichiers Générés

Répertoire `resultats/`

Fichier	Description	Usage
resultats_complets.csv	Données avec scores et clusters	Import dans CRM, analyses complémentaires
analyse_complete.xlsx	Fichier Excel multi-onglets	Présentation à la direction
selection_variables.csv	Résultats V de Cramer	Documentation technique
profils_clusters.csv	Caractéristiques des segments	Définition des personas
modele_statistiques.txt	Statistiques détaillées du modèle	Audit, validation

Répertoire `resultats/figures/`

10 graphiques prêts à l'emploi pour présentations : - Distribution cible, Ranking variables, Corrélations - Méthode du coude, Taille et profils des clusters - Matrice de confusion, Courbe ROC, Importance variables - Distribution des scores

10. ANNEXES TECHNIQUES

A. Description Détaillée des Variables

Variables Démographiques

Variable	Question	Modalités	Description
Q17	Sexe	1=Homme, 2=Femme	Genre du client
Q18	Âge	1=<20, 2=20-30, 3=30-40, 4=40-50, 5=50-60, 6=>60	Tranche d'âge
Q22	CSP	1-9	Catégorie socioprofessionnelle
Q23	Club	1=Oui, 2=Non	Pratique en club sportif
Q21	Budget	1-4	Budget annuel sport

B. Statistiques Avancées du Modèle

Résumé Statsmodels

Logit Regression Results			
=====			
Dep. Variable:	Q10	No. Observations:	225
Model:	Logit	Df Residuals:	217
Method:	MLE	Df Model:	7
Pseudo R-squ.:	0.6045	Log-Likelihood:	-61.680
converged:	True	LL-Null:	-155.94
LLR p-value:	3.091e-37		
=====			

Interprétation : - **Pseudo R^2** = 0.6045 → Le modèle explique 60% de la variance (excellent) - **LLR p-value** < 0.001 → Le modèle est significativement meilleur qu'un modèle nul

C. Glossaire

Terme	Définition
Accuracy	Pourcentage de prédictions correctes
AUC	Aire sous la courbe ROC, mesure la capacité de discrimination
Clustering	Regroupement de données similaires
K-Means	Algorithme de clustering partitionnel
Pseudo R²	Mesure d'ajustement pour modèles logistiques (équivalent du R ²)
ROC Curve	Courbe montrant le compromis sensibilité/spécificité
Score de propension	Probabilité estimée qu'un événement se produise
V de Cramer	Mesure d'association entre deux variables catégorielles

NOTE SUR LE PROJET

Ce rapport présente une analyse complète d'une **étude de cas académique** portant sur l'optimisation du lancement d'une carte de fidélité. Le projet démontre l'application de techniques avancées de Data Science (segmentation, modélisation prédictive, visualisation) dans un contexte business réaliste.

Technologies utilisées : Python, Scikit-learn, Pandas, Statsmodels, Matplotlib, Seaborn

Compétences démontrées : - Analyse exploratoire de données - Sélection de variables (tests statistiques) - Machine Learning (K-Means, Régression Logistique) - Évaluation de modèles (métriques, validation) - Visualisation de données - Communication des résultats

FIN DU RAPPORT