

SCORING ET SEGMENTATION CLIENT

Étude de cas Retail / sport

Projet académique de Data Science

K-Means • Régression logistique • Pipeline scikit-learn

AFFOUDJI Akomédi Paternelle

17/08/2026

Projet académique / portfolio basé sur une étude de cas dans le secteur du retail sportif. Ce dépôt n'est pas affilié à Intersport.

1. Cadre et objectifs

Le fichier rassemble 225 questionnaires et 57 colonnes. La cible Q10 indique si le répondant se déclare intéressé par une carte de fidélité. L'étude répond à deux questions distinctes : décrire des profils de clients sans utiliser la cible, puis estimer la probabilité d'intérêt avec un modèle supervisé.

Segmentation (non supervisée). K-Means est appliqué à quatre variables ordinales ou quantitatives : fréquence de visite (Q4), tranche d'âge (Q18), budget sport annuel (Q21) et nombre de sports pratiqués (Q23).

Scoring (supervisé). Une régression logistique estime l'intérêt déclaré. Le split train/test stratifié précède la sélection de variables. Le V de Cramer, le OneHotEncoder et le modèle sont ajustés uniquement sur le train. La cross-validation est elle aussi limitée au train et réajuste l'ensemble du pipeline dans chaque fold.



Les questions Q11 et Q13 sont conditionnelles à Q10. Q12a-e et Q14 sont également écartées car elles portent directement sur la carte et seraient des proxys trop proches de la cible. Cette décision privilégie une évaluation crédible à une performance artificiellement élevée.

Les résultats sont associatifs et exploratoires. Ils ne démontrent aucune causalité et ne constituent ni une validation commerciale ni une estimation de ROI.

2. Résultats du scoring

Métrique	Valeur
Accuracy	0.765
ROC-AUC	0.866
Precision (classe intéressé)	0.750
Recall (classe intéressé)	0.794
F1-score (classe intéressé)	0.771
CV ROC-AUC sur le train	0.813 $\pm$ 0.073

Matrice de confusion sur les 68 observations du test : TN=25, FP=9, FN=7, TP=27. Le jeu de test n'est utilisé qu'à cette étape d'évaluation finale.



3. Sélection et interprétation

Variable	V de Cramer	p-value
Q7	0.530	4.84e-09
Q23	0.471	8.48e-08
Q5	0.436	3.04e-08
Q6	0.403	3.08e-06
Q3	0.398	2.8e-05
Q4	0.393	2.14e-05
Q18	0.344	0.000158

Le V de Cramer repose sur le test du Chi² et mesure l'association entre deux variables catégorielles. Le seuil de 0,15 est un choix pragmatique pour cette étude. Les p-values sont descriptives : aucune correction pour tests multiples n'est appliquée, et la sélection peut varier sur un autre échantillon.

Modalité	Coefficient log-odds	Odds ratio
Q5_2	-1.553	0.21
Q23_3	1.300	3.67
Q4_5	-1.201	0.30
Q23_4	1.136	3.12
Q18_4	-1.128	0.32


Un odds ratio compare une modalité à la catégorie de référence, toutes choses égales par ailleurs. Il ne correspond pas directement à une variation en pourcentage de probabilité et ne doit pas recevoir une interprétation causale.

4. Segmentation K-Means


Pour $k=3$, l'inertie vaut 539.29, le score de silhouette 0.256 et l'indice de Davies-Bouldin 1.360. Le choix de trois groupes est un compromis de lisibilité : les métriques ne prouvent pas qu'il existe exactement trois populations naturelles.

Groupe	n	%	Q4	Q18	Q21	Q23	Intérêt Q10
Segment 0	94	41.8%	2.46	1.85	1.39	1.04	67.0%
Segment 1	49	21.8%	2.65	3.06	2.45	2.27	81.6%
Segment 2	82	36.4%	4.45	3.82	1.26	1.02	9.8%

Q4 est ordonnée de 1 (visites fréquentes) à 6 (visites rares). Q18 et Q21 sont des tranches ordonnées ; Q23 est un nombre de sports. Le taux Q10 est calculé après le clustering pour décrire les groupes et n'a pas servi à les former.



5. Diagnostic du nombre de groupes



L'inertie diminue mécaniquement quand k augmente. La silhouette et Davies-Bouldin montrent que les groupes restent modérément séparés. Trois clusters sont conservés pour une lecture simple et cohérente avec l'objectif exploratoire, pas parce qu'ils représenteraient une vérité définitive sur la clientèle.

Limite importante : K-Means suppose une distance euclidienne et des groupes approximativement compacts. Même standardisés, des codes de tranches ne garantissent pas des écarts réellement égaux entre modalités. Une analyse sur davantage de données pourrait comparer d'autres représentations ou méthodes adaptées aux données mixtes.

6. Limites et recommandations

- Échantillon limité à 225 questionnaires recueillis en 2002.
- Étude académique, sans validation sur une base externe ni suivi temporel.
- Réponses déclaratives pouvant comporter des biais de questionnaire.
- Sélection univariée et coefficients sensibles au faible effectif.
- Scores calculés pour toute la base avec le modèle ajusté sur le train ; seule la performance du test mesure la généralisation.
- Droits de redistribution du classeur non documentés dans les fichiers source.

Les résultats peuvent servir à formuler des hypothèses de ciblage : adapter le message aux profils observés et utiliser le score comme outil de priorisation à tester. Toute décision marketing devrait être évaluée par une expérimentation séparée avec des coûts et conversions réellement observés. Aucun ROI n'est estimé dans cette étude.

Améliorations possibles : collecter davantage de données, valider le modèle sur une nouvelle période, comparer quelques modèles simples, calibrer les probabilités et étudier la stabilité des clusters.